

第三阶段实验报告：多模型建模与性能优化

本阶段围绕酒店预订取消预测任务开展建模实验。前序阶段已经完成数据清洗、特征工程、编码和时间窗口划分，本阶段直接沿用第二阶段产出的建模数据，重点比较传统机器学习、深度学习、模型融合和业务落地模拟的效果。目标变量为 `is_canceled`，用于判断订单是否被取消。

1. 实验目标与数据基础

本阶段的目标是构建可用于取消预测的分类模型，并从模型性能、模型解释、错误样本和业务收益四个角度评估模型价值。数据集按时间窗口划分为训练集、验证集和测试集，避免随机划分导致未来信息进入训练过程。

dataset	total_count	not_canceled_count	canceled_count	canceled_ratio
train	74132	46712	27420	0.3699
validation	18628	11704	6924	0.3717
test	17868	11192	6676	0.3736

三个数据集的取消率接近，说明时间窗口划分后正负样本比例没有出现明显失衡。这样可以让验证集和测试集更接近模型上线后的时间推移场景。

strategy	not_canceled_count	canceled_count	total_count	canceled_ratio	description
原始训练集	46712	27420	74132	0.3699	不改变样本数量，作为基线训练口径。
SMOTE 过采样	46712	46712	93424	0.5000	只对训练集少数类生成合成样本，使正负样本数量一致。
欠采样	27420	27420	54840	0.5000	只对训练集多数类随机抽样，使正负样本数量一致。
类别权重调整	46712	27420	74132	0.3699	不改变样本数量， <code>class_weight={0: 0.7935, 1: 1.3518}</code> 。

原始训练集取消样本约占 37%，不是极端不平衡问题。SMOTE 和欠采样可以把类别比例调整到 1:1，但会改变训练样本分布；类别权重不改变样本数量，更适合先作为主要处理方式。

2. 传统机器学习模型构建与调优

本阶段实现了逻辑回归、随机森林、XGBoost 和 LightGBM 四种传统分类模型，并使用 Optuna 对关键超参数进行自动搜索。Optuna 会自动尝试不同参数组合，并以验证集 AUC 作为主要优化目标；模型只在训练集上拟合，验证集用于选择较优参数，测试集只用于最终效果评估。这样可以减少手工调参的随意性，也避免直接根据测试集调参。AUC 用于衡量整体排序能力，同时结合 Precision、Recall 和 F1 观察模型在取消识别上的实际表现。

为观察 Optuna 调优效果，本文补充未经过 Optuna 搜索的基线参数模型作为调优前口径，并与 Optuna 调优后的测试集表现进行对比。两组模型使用相同训练集、验证集和测试集，因此可以直接比较调优带来的指标变化。

传统模型调优前后测试集指标对比

模型	基线 AUC	调优后 AUC	AUC 变化	基线 F1	调优后 F1	F1 变化	基线 Precision	调优后 Precision	Precision 变化	基线 Recall	调优后 Recall	Recall 变化
LightGBM	0.9465	0.9485	0.0020	0.8289	0.8326	0.0037	0.8024	0.8113	0.0089	0.8572	0.8552	-0.0020
XGBoost	0.9429	0.9483	0.0054	0.8216	0.8329	0.0113	0.7829	0.8135	0.0306	0.8643	0.8532	-0.0111
Random Forest	0.9350	0.9422	0.0072	0.8153	0.8209	0.0056	0.8054	0.8074	0.0020	0.8253	0.8348	0.0095
Logistic Regression	0.9152	0.9152	0.0000	0.7733	0.7795	0.0062	0.6897	0.7175	0.0278	0.8800	0.8532	-0.0268

从调优前后对比可以看出，XGBoost、Random Forest 和 LightGBM 在 AUC 上均有提升，其中 XGBoost 的 F1 提升最明显。逻辑回归的 AUC 基本不变，但 precision 和 F1 有小幅提升，说明调优主要改善了正类预测的稳定性。整体来看，Optuna 对树模型的效果更明显，对线性模型的提升相对有限。

model	test_auc	test_accuracy	test_precision	test_recall	test_f1	auc_rank
LightGBM	0.9485	0.8716	0.8113	0.8552	0.8326	1
XGBoost	0.9483	0.8721	0.8135	0.8532	0.8329	2
Random Forest	0.9422	0.8639	0.8074	0.8348	0.8209	3
Logistic Regression	0.9152	0.8196	0.7175	0.8532	0.7795	4

LightGBM 和 XGBoost 的 AUC 均达到 0.948 左右，明显高于逻辑回归，说明树模型更能捕捉酒店取消行为中的非线性关系和特征交互。随机森林表现居中，逻辑回归虽然 F1 较低，但提供了清晰的系数解释价值。

model	advantage_scenario	attention_note
LightGBM	预测性能强，测试集 AUC 最高，训练和推理效率较好，适合较大规模结构化表格数据，并可输出特征重要性辅助解释。	可解释性弱于逻辑回归，参数较多；leaf-wise 生长方式拟合能力强，如果约束不足容易过拟合，同时对数据泄露较敏感。
XGBoost	适合结构化表格数据，能够逐轮修正前序模型错误，捕捉非线性和特征交互，测试集 AUC 与 F1 接近 LightGBM。	参数较多，调参成本较高，训练速度通常慢于 LightGBM；作为多棵树叠加模型，可解释性弱于逻辑回归，也存在过拟合风险。
Random Forest	通过多棵决策树投票捕捉非线性关系，对特征尺度不敏感，稳定性较好，整体性能明显优于逻辑回归。	模型体积较大，训练和推理成本较高；虽然有效，但在本项目中的测试集 AUC 和 F1 低于 XGBoost、LightGBM。
Logistic Regression	结构简单、训练速度快、结果稳定且可解释性强，适合作为二分类基线模型，并用于判断特征与取消概率的大致方向。	主要刻画线性关系，对复杂非线性模式和特征交互表达能力有限；在本项目中 AUC、Precision 和 F1 均低于树模型，误判正常订单的比例更高。




图1 传统机器学习模型测试集 AUC 对比




图2 传统机器学习模型测试集 Precision、Recall 与 F1 对比

逻辑回归 precision 低、recall 高，是因为它在类别权重和默认阈值作用下更倾向于预测“取消”；再加上线性模型表达能力有限，容易把一些只是“看起来有风险”的正常订单也判成取消。随机森林更均衡；XGBoost 和 LightGBM 在 precision、recall、F1 之间取得了更好的平衡，更适合作为主要预测模型。

3. 深度学习模型构建与优化

深度学习部分构建了普通 MLP 和 Embedding MLP。普通 MLP 直接使用第二阶段处理后的数值化特征；Embedding MLP 在结构化特征基础上引入类别嵌入表达，用低维稠密向量表示高维类别信息。训练过程中使用早停和学习率衰减，减少无效训练轮次并控制过拟合。

深度学习模型优化主要通过 Early Stopping 和学习率衰减完成。Early Stopping 会持续监控验证集 AUC，当验证集表现连续若干轮没有提升时提前停止训练，避免模型在训练集上继续拟合噪声；学习率衰减则会在训练后期逐步降低参数更新幅度，使模型在接近较优解时更加稳定。通过这两类策略，MLP 和 Embedding MLP 不需要固定训练满所有轮次，而是根据验证集表现自动控制训练过程。

model	auc	accuracy	precision	recall	f1	train_seconds
LightGBM	0.9485	0.8716	0.8113	0.8552	0.8326	11.2600
XGBoost	0.9483	0.8721	0.8135	0.8532	0.8329	36.9800
Embedding MLP	0.9429	0.8615	0.7904	0.8567	0.8222	51.6500
Random Forest	0.9422	0.8639	0.8074	0.8348	0.8209	82.5900
MLP	0.9341	0.8459	0.7648	0.8486	0.8045	40.8000
Logistic Regression	0.9152	0.8196	0.7175	0.8532	0.7795	48.2400

Embedding MLP 的 AUC 高于普通 MLP，说明类别嵌入对结构化酒店订单数据有帮助。但从整体结果看，LightGBM 和 XGBoost 仍然略优，且训练和部署成本更低，因此传统梯度提升树仍是当前数据上的更稳妥选择。




图 3 深度学习模型与传统模型测试集 AUC 对比

4. 模型融合与可解释性分析

模型融合部分补充了多种实验方案，包括三种加权平均融合、不同基模型组合的 Stacking，以及更换元学习器后的 Stacking。这样可以避免只根据单一 Stacking 方案判断融合是否有效。下表同时列出强单模型、MLP、加权平均融合和多种 Stacking 方案，便于直接比较不同融合方式的测试集表现。

model	model_type	dataset	auc	accuracy	precision	recall	f1
LightGBM	single	test	0.9485	0.8716	0.8113	0.8552	0.8326
XGBoost	single	test	0.9483	0.8721	0.8135	0.8532	0.8329
Weighted_Average_LGBM_Heavy	weighted_average	test	0.9485	0.8720	0.8117	0.8561	0.8333
Weighted_Average_Tree_Heavy	weighted_average	test	0.9484	0.8721	0.8130	0.8543	0.8331
Weighted_Average_Equal	weighted_average	test	0.9476	0.8710	0.8097	0.8559	0.8322
Stacking_A_LR_XGB_LGBM_MLP	stacking	test	0.9480	0.8713	0.8089	0.8583	0.8328
Stacking_B_LR_RF_LGBM_MLP	stacking	test	0.9477	0.8708	0.8091	0.8562	0.8320
Stacking_C_RF_Meta	stacking	test	0.9485	0.8726	0.8176	0.8481	0.8326
Stacking_D_LGBM_Meta	stacking	test	0.9485	0.8735	0.8193	0.8487	0.8337
MLP	single	test	0.9341	0.8459	0.7648	0.8486	0.8045

从结果看，Weighted_Average_LGBM_Heavy、Stacking_C_RF_Meta 和 Stacking_D_LGBM_Meta 的 AUC 均接近 0.9485，与 LightGBM 基本持平。其中 Stacking_D_LGBM_Meta 的 accuracy、precision 和 F1 略高，但提升幅度很小；Stacking_A/B 以及等权平均融合也没有形成稳定优势。因此，当前特征体系下融合方案有提升，但相对于 LightGBM、XGBoost 的边际增益有限。




图4 单模型、深度学习模型与融合模型测试集 AUC 对比

可解释性部分从逻辑回归系数和 SHAP 值两个角度观察特征影响。逻辑回归系数提供方向信息，SHAP 则衡量树模型中每个特征对预测结果的平均影响强度。

feature_name	logistic_score	xgboost_shap_score	lightgbm_shap_score	combined_score
country_target_encoded	5.8501	0.6442	0.7492	0.8473
deposit_type_Non_Refund	3.0201	0.7033	1.1971	0.8387
cancellation_risk_score_scaled	1.5784	0.6453	0.7793	0.6128
agent_target_encoded	2.3171	0.3565	0.3691	0.4038

required_car_parking_spaces_scaled	2.5381	0.2833	0.4314	0.3990
previous_cancellations_scaled	1.5894	0.2616	0.3888	0.3228
deposit_type_No_Deposit	0.7336	0.3046	0.3508	0.2838
reserved_room_type_P	4.9421	0.0000	0.0000	0.2816
room_type_matched_scaled	0.7567	0.2579	0.3048	0.2502
total_of_special_requests_scaled	0.2894	0.2525	0.2897	0.2168

综合排序靠前的特征包括国家或地区历史取消倾向、押金类型、取消风险评分、代理商信息、停车位需求、历史取消次数、房型类别、房型是否匹配以及特殊需求数量。这些特征共同反映了订单来源、取消政策、历史行为、房型安排和用户预订意图对取消风险的影响。




图 5 逻辑回归特征系数 Top 20

图 5 说明：逻辑回归特征系数图展示线性模型中各特征的影响方向。红色表示该特征会提高模型对取消的判断倾向，蓝色表示该特征会降低取消判断倾向，柱子越长说明影响越强。




图6 XGBoost SHAP 特征重要性 Top 20

图6说明：XGBoost SHAP 图展示各特征对 XGBoost 预测结果的平均影响强度。押金类型、取消风险评分和国家或地区历史取消倾向排名靠前，说明这些变量是 XGBoost 判断取消风险的重要依据。




图7 LightGBM SHAP 特征重要性 Top 20

图7说明：LightGBM SHAP 图展示 LightGBM 模型中的特征重要性。其靠前特征与 XGBoost 基本一致，说明押金类型、取消风险评分和国家或地区历史取消倾向在不同树模型中都具有较稳定的重要性。




图8 影响预订取消的 Top 10 核心特征

图8说明：综合 Top 10 图对应上方核心特征表。该图综合逻辑回归系数、XGBoost SHAP 和 LightGBM SHAP 得分，展示多个解释方法下共同重要的取消风险因素。

综合图5至图8可以看出，不同解释方法得到的核心影响因素具有较高一致性。逻辑回归系数强调特征对取消概率的正负方向，XGBoost 和 LightGBM 的 SHAP 结果强调特征对模型预测的平均影响强度，综合 Top 10 则用于筛选多个模型共同认为重要的变量。整体来看，国家或地区历史取消倾向、押金类型、取消风险评分、代理商信息、历史取消次数、房型安排和特殊需求数量等特征在多个解释结果中反复出现，说明模型主要依靠订单来源、取消约束、历史行为和用户预订意图来判断取消风险。这些结果只能说明模型预测依据，不代表这些因素一定会因果性地导致取消。

5. 预测错误样本分析

error_type	sample_count	sample_ratio
预测正确	15568	0.8713
误判：实际未取消但预测取消	1354	0.0758
漏判：实际取消但预测未取消	946	0.0529

错误样本中误判数量高于漏判，说明当前阈值下模型更倾向于识别取消风险。这种策略有助于提高取消订单召回，但也会让部分正常订单被划入高风险，需要在业务干预强度上保持克制。

scenario	scenario_count	scenario_cancel_rate	scenario_error_rate	error_rate_gap
冷启动近似样本	16315	0.3514	0.1388	0.1156
特殊日期近似样本	10732	0.3709	0.1285	-0.0006
周末入住	5460	0.3731	0.1330	0.0061
节假日代理变量	5460	0.3731	0.1330	0.0061
节假日前后代理变量	5272	0.3687	0.1239	-0.0069

冷启动近似样本的错误率明显高于非冷启动样本，说明历史行为信息不足时模型判断更不稳定。特殊日期近似样本与非特殊日期样本的错误率差异很小，当前数据中日期代理变量并没有造成明显额外误差。




图9 最优融合模型预测错误类型分布




图10 冷启动与特殊日期场景预测错误率

6. 业务落地模拟设计

6.1 取消风险评分生成

本节使用 LightGBM 模型为测试集中的每笔订单计算取消风险分数。风险分数越高，表示模型认为该订单被取消的可能性越大。前面的建模实验主要回答“模型能不能预测取消”，而业务落地模拟进一步关注“预测结果如何被业务使用”。因此，本节将模型概率转化为风险分层，并通过阈值模拟观察模型结果是否具有实际应用价值。

具体来说，本文先按照取消风险分数将订单划分为低风险、中风险、高风险和极高风险四类，并统计不同风险层级下的订单数量、实际取消率、平均风险分数和订单占比。如果风险分层有效，高风险层级的实际取消率应明显高于低风险层级。

6.2 风险分层统计

risk_segment	order_count	canceled_count	actual_cancel_rate	avg_risk_score	order_share
低风险	9029	441	0.0488	0.0676	0.5053
中风险	1802	526	0.2919	0.3953	0.1009
高风险	1396	701	0.5021	0.5956	0.0781
极高风险	5641	5008	0.8878	0.9227	0.3157

风险分层表用于检验模型分数是否具有业务区分度。order_count 表示该风险层级包含多少订单，canceled_count 表示其中实际取消的订单数量，actual_cancel_rate 表示该层级的真实取消率，avg_risk_score 表示模型给出的平均风险分数，order_share 表示该层级订单在测试集中的占比。

从风险分层结果看，低风险订单的实际取消率较低，而高风险和极高风险订单的实际取消率明显更高，说明模型输出的风险分数能够把取消风险不同的订单区分开。极高风险订单占比约三成，但贡献了大量取消样本，是后续业务干预和库存管理需要重点关注的对象。




图 11 取消风险分层统计

6.3 干预阈值与收益模拟

thresho ld	touched_orde rs	touch_ra te	touched_canceled_ord ers	Cancel_reca ll	precisi on	estimated_saved_reve nue	intervention_co st	estimated_net_bene fit
0.3000	8839.00	0.4947	6235.00	0.9339	0.7054	148944.98	44195.00	104749.98
0.3500	8350.00	0.4673	6135.00	0.9190	0.7347	146169.98	41750.00	104419.98
0.4000	7893.00	0.4417	6003.00	0.8992	0.7605	142895.95	39465.00	103430.95
0.4500	7413.00	0.4149	5850.00	0.8763	0.7892	138572.38	37065.00	101507.38
0.5000	7037.00	0.3938	5709.00	0.8552	0.8113	134953.50	35185.00	99768.50
0.5500	6635.00	0.3713	5540.00	0.8298	0.8350	130447.35	33175.00	97272.35
0.6000	6305.00	0.3529	5369.00	0.8042	0.8515	125794.80	31525.00	94269.80
0.6500	5959.00	0.3335	5181.00	0.7761	0.8694	121029.51	29795.00	91234.51
0.7000	5641.00	0.3157	5008.00	0.7501	0.8878	116060.35	28205.00	87855.35
0.7500	5338.00	0.2987	4819.00	0.7218	0.9028	110955.12	26690.00	84265.12
0.8000	4947.00	0.2769	4564.00	0.6836	0.9226	103117.35	24735.00	78382.35

干预阈值（threshold）可以理解为“从多少风险分数开始采取业务动作”。阈值越低，被触达的订单越多，可以覆盖更多真实取消订单，但也会增加干预成本；阈值越高，干预更精准，但可能漏掉一部分本来可以挽回的取消订单。

阈值模拟表中的 `touched_orders` 表示达到该阈值并被触达的订单数量，`touch_rate` 表示触达比例，`touched_canceled_orders` 表示被触达订单中真实取消的数量，`Cancel_recall` 表示真实取消订单中有多少被覆盖。`estimated_net_benefit` 是扣除模拟干预成本后的预估净收益，用于比较不同阈值的相对效果。

阈值模拟中，0.30 阈值下预计净收益最高。该阈值覆盖订单较多，能够召回更多历史取消订单；随着阈值提高，干预更精准，但覆盖的取消订单减少，模拟净收益逐步下降。

6.4 模拟 A/B 测试方案

实验对象选取模型判断为高取消风险的订单。结合当前离线模拟结果，可以先将 `cancel_risk_score` 不低于 0.30 的订单作为候选实验对象，因为该阈值能够覆盖较多历史取消订单，同时在模拟测算中净收益最高。

实验组对这些高风险订单采取干预措施，例如发送确认短信、入住前二次确认、提供灵活改期方案，或在部分订单中设置押金、信用卡担保等规则。具体干预强度需要结合酒店实际运营成本和用户体验谨慎设置。

对照组同样来自 `cancel_risk_score` 不低于 0.30 的高风险订单，但不采取额外干预，继续按照原有订单处理流程执行。这样可以比较“模型驱动干预”和“原有处理方式”之间的效果差异。

实验分组时需要在高风险订单中随机分配实验组和对照组，并尽量保证两组在酒店类型、分销渠道、入住月份、房价水平和风险分数分布上接近，避免因样本结构不同影响实验结论。

核心评估指标包括取消率变化、收入变化和用户满意度。取消率变化用于观察实验组是否比对照组更少取消；收入变化用于比较干预后保留下来的订单收入是否增加；用户满意度可以通过投诉率、客服咨询率、短信退订率、用户评分等指标观察。当前离线数据没有满意度字段，因此这部分需要在真实上线实验中额外采集。

如果实验组取消率低于对照组，同时净收益为正且用户满意度没有明显下降，说明模型驱动的高风险订单干预具有实际推广价值。反之，如果取消率改善不明显或用户体验受损，则需要调整干预阈值、干预方式或只对更高风险订单采取动作。




图 12 不同干预阈值下的模拟净收益

图 12 展示了不同干预阈值下的预估净收益变化。结果显示，threshold = 0.30 时净收益最高；随着阈值升高，触达订单减少，虽然干预更精准，但可覆盖的真实取消订单也减少，因此预估净收益整体下降。该图用于辅助选择候选干预阈值，但结果依赖离线模拟参数，不代表真实上线收益。

6.5 收益管理优化建议

基于风险评分和阈值模拟结果，模型可以为酒店收益管理提供订单级参考。这里的建议不是只关注高风险订单，而是同时兼顾两类目标：一方面对高取消风险订单进行风险控制，减少潜在取消损失；另一方面保护低风险订单和已经较稳定的预订收入，避免因沟通不足、体验预期不清或过度干预导致原本稳定的订单流失。

动态定价策略：针对高取消风险订单，可以优先采用信用卡担保、押金、缩短免费取消窗口，或提供不可退款低价选项。这样做的目的不是简单提高价格，而是通过提高取消成本或提供差异化价格选择，减少高风险订单临近入住取消带来的收入损失。对低风险订单则应以保护已有预订收入为目标，保留更灵活的取消政策，并通过入住提醒、订单信息确认、会员权益提示等低打扰方式维护用户体验，避免把原本稳定的订单变成流失风险。但仍需注意在低风险用户身上投入资源所产生的边际效益递减的问题，需要预防过量的投入资源到低风险用户身上。

渠道库存分配策略：不同渠道的订单取消风险和收入表现不同。对于取消风险较高、订单波动较大的渠道，可以在旺季或库存紧张时适度收紧库存释放，或提高担保要求；对于取消率较低、收入较稳定的渠道，可以优先保障库存，减少因库存不足或服务响应不足导致的稳定订单流失。这样既能降低高风险订单占用库存后取消造成的机会损失，也能保护已经较确定的预订需求。

取消政策优化建议：酒店应保留统一、透明的基础取消政策，避免让用户感知到规则不一致。在此基础上，可以通过公开的产品选项进行差异化，例如同时提供“可免费取消但价格略高”和“不可退款但价格更低”的房价方案，让用户根据自身需求选择。这样既能保持规则透明，也能减少高风险订单临近取消带来的空房损失。

6.6 预期业务收益量化

本节基于模型预测结果，对模型应用后的潜在业务收益进行离线测算。计算思路是：当订单的 `cancel_risk_score` 不低于某一干预阈值时，将该订单纳入干预范围；假设干预可以挽回一部分真实会取消的订单，并扣除短信、人工确认、押金流程等干预成本，从而估算模型应用后可能减少的取消损失。

本次模拟使用三个核心参数：每单干预成本、干预挽回率和收入挽回比例。`estimated_saved_revenue` 表示预计可减少的取消损失，`intervention_cost` 表示干预成本，`estimated_net_benefit` 表示扣除干预成本后的预估净收益。

从阈值模拟结果看，`threshold = 0.30` 时预计净收益最高。该阈值下共触达 8839 笔订单，覆盖 6235 笔历史取消订单，预计减少取消损失 148944.98，扣除 44195.00 的干预成本后，预估净收益为 104749.98。

需要注意的是，该结果依赖离线模拟假设，只能说明模型具有潜在业务价值，不能直接代表真实上线收益。真实业务中仍需要通过 A/B 测试验证干预措施是否真的能降低取消率并提升收入。

7. 阶段结论

传统机器学习模型中，LightGBM 和 XGBoost 表现最稳定，AUC 和 F1 均处于领先水平。Optuna 调优后，XGBoost、Random Forest 和 LightGBM 的 AUC 均有提升，说明自动超参数搜索对树模型效果更明显。

深度学习模型中，Embedding MLP 相比普通 MLP 有提升，说明类别嵌入对结构化订单数据有一定帮助，但整体表现仍未超过 LightGBM 和 XGBoost。

多种融合方案可以达到强单模型水平，部分 Stacking 和加权平均方案在 accuracy、precision 或 F1 上略有提升，但整体提升幅度较小，说明当前特征体系下融合模型的边际收益有限。

模型可解释性分析显示，国家或地区历史取消倾向、押金类型、取消风险评分、代理商信息、历史取消次数、房型安排和特殊需求数量是影响取消预测的重要因素。

错误样本分析显示，冷启动近似订单的预测错误率高于非冷启动订单，说明缺少历史行为信息时模型判断更不稳定。

业务模拟结果显示，模型风险分层与真实取消率基本一致，风险越高的订单实际取消率越高。阈值模拟中，`threshold = 0.30` 时预估净收益最高，说明模型结果具备一定业务应用价值。

基于模型结果，本文进一步设计了高风险订单模拟 A/B 测试方案，并提出动态定价、渠道库存分配和取消政策优化建议。相关收益测算仍属于离线模拟，真实效果需要通过线上实验验证。

8. 注意事项

当前数据没有真实用户 ID，冷启动用户只能用历史行为字段进行近似识别，不能解释为真实新用户。

节假日变量为特征工程阶段构建的代理变量，不等同于真实法定节假日。

收益测算使用离线模拟参数，真实干预成本、挽回率和用户满意度需要通过 A/B 测试验证。

报告中的特征重要性和 SHAP 结果反映模型预测依据，不代表因果关系。

收益管理建议属于基于模型结果的模拟方案，实际执行时需要结合酒店品牌策略、渠道合作规则、用户体验和合规要求，不能直接用模型分数替代业务判断。

9. 阶段产出

- 第三阶段建模 Notebook: notebooks/modeling_sample_construction.ipynb。
- 样本构建与数据集划分结果：目标变量定义、时间窗口划分、训练/验证/测试集样本分布、样本平衡策略说明，以及城市酒店和度假酒店独立样本评估结果。
- 传统机器学习模型结果：默认基线模型、Optuna 调优结果、调优前后对比表、最终模型性能表和指标对比图。
- 深度学习模型结果：MLP、Embedding MLP 训练结果，以及与传统模型的性能对比表和图。
- 模型融合结果：加权平均融合、多组 Stacking 融合方案的性能对比表和 AUC 对比图。
- 模型可解释性结果：逻辑回归系数、XGBoost/LightGBM SHAP 解释结果、Top 10 核心特征表 and 对应可视化图。
- 预测错误样本分析结果：错误类型统计、冷启动近似场景与特殊日期场景错误率分析。
- 业务落地模拟结果：取消风险评分、风险分层统计、阈值收益模拟、模拟 A/B 测试方案、收益管理优化建议和预期业务收益量化。
- 第三阶段实验报告: reports/第三阶段实验报告.docx。

10. 下一阶段目标

1. 代码工程化封装。
2. 项目文档与汇报材料撰写
3. 项目复盘与总结
4. 成果提交与展示

