

酒店预订行为与取消预测项目

第二阶段实验报告

SQLite 数据库搭建、SQL 分析、特征体系构建、特征预处理与 EDA

生成日期：2026-06-26

1. 实验背景

第一阶段已经完成原始酒店预订数据的读取、合规性检查、缺失值处理、异常值处理、时间字段统一和清洗结果保存。第二阶段在清洗后数据基础上，继续完成数据库化管理、SQL 统计分析、特征体系构建、特征预处理与多维度探索性数据分析，为后续建模阶段做准备。

2. 实验目标

- 搭建 SQLite 数据库，形成预订主表、客户维度表、酒店维度表和时间维度表。
- 编写批量导入脚本，将预处理后的 Parquet 数据导入 SQLite。
- 建立日期、酒店类型、客户类型和取消行为相关索引，提升常用查询效率。
- 完成基础 SQL 统计分析，包括预订量、取消率、渠道、市场细分、时间趋势和提前预订天数等。
- 构建覆盖时间、预订、客户、价格、收益管理和风险方向的特征体系。
- 完成类别编码、数值标准化、特征筛选和特征重要性预评估。
- 完成多维度 EDA，观察取消行为、价格、渠道、客户群体和季节性特征。

3. 使用工具与环境

类别	说明
开发环境	VS Code、Jupyter Notebook
编程语言	Python
主要 Python 库	pandas、pathlib、sqlite3、matplotlib、seaborn、scikit-learn
数据库	SQLite
报告生成	python-docx

4. 数据输入与阶段产出概览

数据对象	路径	规模
------	----	----

清洗后数据	data/processed/hotel_bookings_cleaned.csv	110,628 行, 35 列
特征工程数据	data/processed/hotel_booking_features.parquet	110,628 行, 86 列
训练集	data/processed/modeling_dataset_train.parquet	74,132 行, 169 列
验证集	data/processed/modeling_dataset_validation.parquet	18,628 行, 169 列
测试集	data/processed/modeling_dataset_test.parquet	17,868 行, 169 列

5. 实验过程与结果

5.1 SQLite 数据库搭建与 SQL 基础分析

数据库使用四张基础表和一个分析视图组织数据。bookings 保存订单事实数据, customer_profile、hotel_summary 和 time_dimension 分别保存客户、酒店和时间维度。booking_analysis_view 用于基础 SQL 分析, 减少重复编写多表关联逻辑。

对象名	类型	行数	字段数	说明
bookings	table	110,628	28	预订主表, 保存订单事实数据
customer_profile	table	121	5	客户维度表, 保存客户类型与渠道属性
hotel_summary	table	30	4	酒店维度表, 保存酒店和城市属性
time_dimension	table	366	8	时间维度表, 保存入住日期拆分信息
booking_analysis_view	view	110,628	39	分析视图, 用于基础 SQL 统计

索引设计覆盖日期、酒店、客户、取消状态、订金类型和提前预订天数等常用查询字段。其中复合索引用于支持按时间与酒店、客户与取消状态、订金类型与提前预订天数等组合条件查询。

指标		结果		
总预订量		110,628		
取消订单量		41,020		
整体取消率		37.08%		
平均房价 ADR		97.01		
平均提前预订天数		103.37		
平均入住晚数		3.04		
市场细分	预订量	预订占比	取消率	平均 ADR
Online TA	51,533	46.58%	35.56%	110.88
Offline TA/TO	22,461	20.30%	35.97%	86.65
Groups	19,417	17.55%	61.37%	78.80
Direct	11,144	10.07%	14.44%	104.42
Corporate	5,123	4.63%	18.47%	69.32

SQL 结果显示，Online TA 是主要市场来源，占比约 46.58%；TA/TO 是主要分销渠道，占比约 82.16%。Groups 市场细分取消率较高，Direct 和 Corporate 渠道取消率相对较低。Undefined 类别样本量极小，不能仅凭取消率作强结论。

5.2 全维度特征体系构建

特征工程基于清洗后数据构建，输出 110,628 行、86 列的特征数据，并生成 39 条特征字典记录。

特征类别	代表字段	作用
时间特征	arrival_month、arrival_quarter、arrival_day_of_week、is_weekend、season_type	刻画入住时间、周末和淡旺季差异。
预订行为特征	total_stays、total_guests、has_children_or_babies、room_type_matched	刻画订单规模、入住晚数、同行结构和房型匹配情况。
客户与 RFM 特征	customer_group_key、rfm_value_score、rfm_segment、is_high_value_customer_group	在没有真实 user_id 的前提下，基于客户群体近似刻画客户价值。
历史风险特征	customer_group_hist_cancel_rate、country_hist_cancel_rate、agent_hist_cancel_rate	用历史取消率刻画客户群体、国家和代理商风险。
价格特征	price_to_hotel_hist_avg、price_volatility_index、price_sensitivity_score	刻画当前价格相对历史均价和客户群体历史价格区间的差异。
收益管理特征	estimated_occupancy_proxy、demand_pressure_score	基于当日酒店预订量构造入住率 and 需求紧张程度的代理变量。

节假日字段当前没有引入外部法定节假日数据，使用周末作为节假日代理。该字段可以用于探索，但在业务解释时需要说明其局限。

5.3 特征预处理与有效性验证

特征预处理改为按 arrival_date 的时间窗口划分数据：2024 年 1-8 月为训练集，9-10 月为验证集，11-12 月为测试集。类别编码、数值标准化和特征有效性预评估仍然只在训练集上学习规则，再应用到验证集和测试集，从而更接近“使用历史月份预测未来月份”的业务场景。

处理项	结果
候选输入特征数	82
训练集行数	74,132
验证集行数	18,628
测试集行数	17,868
标准化数值特征数	61
Target Encoding 特征数	4

One-Hot 输出特征数	103
方差阈值筛选后特征数	167
数据划分方式	按 arrival_date 时间窗口划分：1-8 月训练，9-10 月验证，11-12 月测试

高维类别字段 country、agent、hotel 和 customer_group_key 使用 Target Encoding；低维类别字段使用 One-Hot Encoding；数值字段使用 StandardScaler 标准化。特征筛选使用方差阈值、相关性分析和互信息法进行初步检查。

随机森林特征预评估	结果
训练集 AUC	0.9307
验证集 AUC	0.9260
测试集 AUC	0.9258

随机森林在此处仅用于特征重要性预评估和验证特征信号，不作为最终模型结论。正式建模阶段仍需要比较多种模型、调参，并结合交叉验证和独立测试集评价。




图 5-1 特征相关性热力图

该热力图选取与目标变量相关性较高的前 20 个预处理后特征，展示特征之间以及特征与 is_canceled 之间的线性相关关系。可以看到取消风险评分、订金类型、国家/代理商历史取消率等变量与目标变量关系较强；同时部分历史取消率类特征之间存在相关性，后续建模需要关注冗余和数据泄露控制。




图 5-2 随机森林特征重要性 Top 20

重要性排序显示，取消风险评分、订金类型、国家和代理商相关风险特征、提前预订天数等变量在随机森林预评估中排名靠前。该排序用于判断特征信号强弱，不代表最终模型解释结果；正式建模阶段仍需结合验证集表现和可解释性方法确认。

特征名称	随机森林重要性
cancellation_risk_score_scaled	0.1376
deposit_type_Non_Refund	0.0906
country_target_encoded	0.0668
deposit_type_No_Deposit	0.0539
agent_target_encoded	0.0502
country_hist_cancel_rate_scaled	0.0430
agent_hist_cancel_rate_scaled	0.0427
customer_group_key_target_encoded	0.0408
lead_time_scaled	0.0363

lead_time_group_0_7	0.0360
---------------------	--------

5.4 多维度探索性数据分析

EDA 使用特征工程后的原始尺度特征进行分析，没有使用标准化后的建模数据。这样可以保留 ADR、提前预订天数、入住晚数等字段的业务解释性。

EDA 指标	结果
月度预订量范围	8,861 至 9,567
月度取消率范围	36.49% 至 38.06%
月度平均 ADR 范围	96.22 至 97.69

从月度趋势看，本数据集各月预订量较均衡，取消率大约在 36.49% 到 38.06% 之间，波动幅度不大。前面折线图看起来波折明显，主要是因为取消率坐标轴范围较窄；扩大坐标轴后更能看出月度取消率整体比较稳定。

提前预订天数组	预订量	取消率	平均 ADR
0-7	19,039	9.45%	86.02
8-30	17,566	27.06%	101.43
31-90	27,373	37.66%	100.78
91-180	23,920	45.38%	104.39
181+	22,730	58.53%	90.51

提前预订天数与取消率呈明显正相关趋势：0-7 天预订取消率约 9.45%，181 天以上预订取消率约 58.53%。这说明 lead_time 是后续建模中需要重点关注的字段。

季节类型	预订量	取消率	平均 ADR
平季	55,286	37.05%	96.94
旺季	28,613	36.95%	96.90
淡季	26,729	37.27%	97.28

淡旺季分组后，预订量、取消率和平均房价差异不明显。当前分组更多是业务假设和特征储备，不能单独说明季节性对取消行为有强影响。




图 1 目标变量分布

从图 1 可以看出，取消订单占 37.08%，未取消订单占 62.92%。两类样本并非完全均衡，但取消样本占比不低，后续模型评估不能只看准确率，还需要结合 AUC、召回率、精确率和 F1 值判断模型对取消订单的识别能力。



图 2-4 酒店月度预订量、取消率与平均房价趋势

从图 2-4 可以看出，City Hotel 的月度预订量整体高于 Resort Hotel，同时 City Hotel 的取消率也明显更高；City Hotel 月度取消率约在 40.83% 至 42.27% 之间，Resort Hotel 约在 24.70% 至 28.51% 之间。两类酒店各自的月度波动不大，说明当前样本中酒店类型差异比月份差异更明显。




图 8 提前预订天数分组与取消率

从图 8 可以看出，提前预订天数越长，取消率整体越高。0-7 天组取消率约为 9.45%，181 天以上组取消率约为 58.53%，呈现较清晰的递增趋势。因此 `lead_time` 是取消预测中值得重点保留和验证的变量，但该图只能说明统计相关性，不能直接解释因果关系。




图 9 订金类型与取消率

从图 9 可以看出，No Deposit 是样本量最大的订金类型，取消率约为 27.71%；Non Refund 样本量约 14,479 条，但取消率高达 99.37%。该结果说明订金类型与取消状态高度相关，但 Non Refund 的异常高取消率可能受

业务记录口径影响，后续建模时需要关注该字段是否会形成过强的结果信号。Refundable 样本量仅 154 条，不能仅凭比例作稳定结论。




图 13-14 RFM 客户群体对比

从图 13-14 可以看出，高价值客户群体占绝大多数订单，且平均估算消费金额明显高于其他群体；潜力、沉睡和流失群体样本量较小，取消率较低但稳定性有限。需要注意的是，当前数据没有真实 user_id，RFM 分群是基于客户类型、市场细分、分销渠道和是否回头客构造的客户群体近似，不能解释为真实单个用户的生命周期分层。




图 21-23 淡旺季预订量、取消率与平均房价

从图 21-23 可以看出，按当前样本月度预订量划分的淡季和旺季在预订量、取消率和平均房价上差异都不明显；旺季取消率约为 36.95%，淡季约为 37.27%，平均 ADR 也都接近 97。因此当前淡旺季口径更适合作为候选特征保留，不能单独证明季节性对取消行为有强影响。

6. 阶段性结论

- 第二阶段已形成 SQLite 数据库，bookings 主表包含 110,628 条预订记录。
- 整体取消率为 37.08%，is_canceled 可作为后续二分类建模目标变量。

- 渠道、市场细分、订金类型、提前预订天数和历史取消行为是取消风险分析中的重要方向。
- 特征工程共输出 86 列数据，覆盖时间、预订行为、客户群体、价格、收益管理和风险特征。
- 特征预处理完成训练集、验证集和测试集划分，并生成可直接用于建模的数据集。
- EDA 显示月度取消率和淡旺季差异不强，但提前预订天数、订金类型和部分渠道差异较明显。

7. 核心数据洞察与业务优化建议

用户行为规律：当前样本中，月度预订量和月度取消率整体较稳定，淡旺季差异不强；酒店类型差异更明显，City Hotel 的预订量和取消率均高于 Resort Hotel。提前预订天数越长，取消率越高，说明长提前期订单的不确定性更强。

取消风险因素：提前预订天数、订金类型、市场细分、分销渠道、客户类型、历史取消率和特殊需求数量是本阶段观察到的主要风险相关因素。其中 Non Refund 取消率极高，可能与业务记录口径有关，后续建模和业务解释时需要谨慎核查。

用户分群洞察：由于原始数据没有真实 user_id，本项目的 RFM 分群是基于客户类型、市场细分、分销渠道和是否回头客构造的客户群体近似。高价值客户群体订单占比最高且估算消费金额更高，但不能解释为真实单个用户生命周期分层。

业务优化建议：对 91 天以上、181 天以上的长提前期订单可设置更早的二次确认、提醒或风险监控；对高取消率渠道和市场细分可复核分销政策与订单确认机制；对订金类型和取消规则应结合业务口径进一步核查，避免模型只学习到结果性字段；对高风险国家/地区或代理商可在后续模型验证后用于运营预警。

后续落地建议：正式建模阶段应继续保持训练集内拟合编码、历史取消率和评分规则，避免数据泄露；上线前应结合业务人员确认字段在预测时点是否可获得。

8. 局限说明

- 原始数据没有真实 user_id，客户价值和 RFM 分群是基于客户群体维度的近似，不代表真实单个用户。
- 节假日特征当前使用周末代理，没有法定节假日数据。
- 入住率预估和需求紧张程度基于预订量代理计算，不等同于酒店真实库存和实际入住率。

9. 阶段产出

产出类型	路径
SQLite 建库脚本	src/database/build_sqlite_database.py
SQL 分析脚本	src/database/run_sql_analysis.py
SQL 查询文件	sql/basic_analysis.sql

数据库设计说明	docs/sqlite_database_design.md
特征工程 Notebook	notebooks/feature_engineering.ipynb
特征预处理 Notebook	notebooks/feature_preprocessing_validation.ipynb
EDA Notebook	notebooks/eda_analysis.ipynb
SQL 分析结果	reports/sql_analysis/*.csv
EDA 图表	reports/eda_figures/*.png
建模数据集	data/processed/modeling_dataset_*.parquet
特征工程脚本	src/features/build_feature_dataset.py
特征预处理脚本	src/features/preprocess_feature_dataset.py
详细特征字典脚本	src/features/build_detailed_feature_dictionary.py
相关性热力图	reports/feature_correlation_heatmap.png
特征重要性排序图	reports/feature_importance_top20.png

10. 下一阶段计划

- 进入正式建模阶段，比较逻辑回归、随机森林、梯度提升树等模型表现。
- 基于验证集进行模型调参，并在测试集上输出最终评估指标。
- 结合特征重要性、Permutation Importance 或 SHAP 分析模型可解释性。
- 围绕高取消风险订单设计业务解释和运营建议，例如订金策略、提前预订风险识别和渠道管理。