

第一阶段实验报告：项目启动、数据清洗与中间表构建

酒店预订行为与取消预测项目

一、实验背景

本项目围绕酒店预订行为与取消预测展开，目标是基于酒店订单数据分析用户预订行为，并为后续取消预测建模提供规范的数据基础。

二、实验目标

- 搭建 Git 版本管理体系和项目目录结构。
- 精读多篇酒店预定取消预测的论文并生成调研笔记。
- 完成原始酒店预订数据的读取和基础概览。
- 对原始数据集进行合规性校验。
- 执行多维度数据清洗，包括缺失值处理、异常值处理、去重检查和时间格式统一。
- 开发自动化数据质量校验脚本，用于后续同结构数据的快速复查。
- 构建清洗后数据集、Parquet 文件和基础聚合中间表。
- 生成实验报告

三、实验环境与工具

类别	内容
编程语言	Python
数据分析库	pandas、matplotlib、scikit-learn
数据存储格式	CSV、Parquet
版本管理	Git、GitHub
开发环境	VS Code

项目采用模块化目录结构，将原始数据、清洗后数据、中间表、Notebook、脚本、文档和报告分别管理，便于后续扩展和复查。

```
hotel-booking-analysis/  
  data/  
    raw/  
    processed/  
    intermediate/  
  docs/  
  notebooks/  
  reports/  
  src/  
    data/  
    config.py
```

四、Git 版本管理体系

本项目已完成 GitHub 仓库和本地 Git 仓库连接，远程仓库为：
<https://github.com/tedxu222-cpu/hotel-booking-analysis>。

分支	用途
main	稳定成果和对外展示版本。
dev	阶段整合和检查版本。
feature/project-setup	当前第一阶段项目启动与数据工程开发分支。

提交信息规范已写入 docs/git_workflow.md。本项目 commit message 采用 <type>: <中文说明> 格式，例如 clean: 完成缺失值与异常值处理。

五、数据读取与基础概览

原始数据文件位于 data/raw/hotel_bookings_updated_2024.csv。读取方式使用项目相对路径，避免使用绝对路径。

指标	结果
----	----

原始数据行数	119390
原始数据列数	33
目标变量	is_canceled

数据包含酒店类型、是否取消、提前预订天数、入住日期、入住晚数、客人数量、餐饮类型、来源国家、市场细分、分销渠道、历史取消记录、房型、押金类型、代理商、公司、平均每日房价、停车位需求、特殊请求、预订状态、城市等字段。

六、原始数据合规性校验

本阶段对原始数据进行了基础合规性校验，主要覆盖字段完整性、目标变量有效性、缺失情况、重复情况和字段一致性。

检查项	结果
数据文件是否存在	存在，且可以正常读取。
项目说明中的预期字段	均存在。
额外字段	实际数据比项目说明多出 city 字段。
city 字段处理	项目说明中没有解释，当前仅记录为额外字段，暂不删除。
预订唯一 ID	当前数据没有发现明确的预订唯一 ID 字段。
完全重复行	0 行。

由于 city 字段没有在项目说明的数据字典中给出解释，本阶段不强行解释其业务含义，仅将其视为额外字段进行记录。

七、目标变量检查

项目说明文件中明确 is_canceled 是目标变量，其含义为 0 表示未取消，1 表示取消。

检查项	结果
目标变量	is_canceled
取值范围	0、1
非法取值数量	0
缺失数量	0
任务判断	二分类任务

八、数据清洗过程

8.1 缺失值处理

本阶段针对项目要求中的 children、agent、company 三个字段进行缺失值填补。

字段	处理方式	说明
children	使用 0 填补	表示儿童数量缺失时按 0 处理。
agent	使用 0 填补	匿名代理商 ID 字段，缺少数据字典支持，不强行解释业务含义。
company	使用 0 填补	匿名公司 ID 字段，缺少数据字典支持，不强行解释业务含义。

agent 和 company 的缺失可能具有业务含义，但当前缺少更明确的数据字典支持，因此本阶段只做基础缺失填补。是否构造缺失标记字段，留到后续特征工程阶段判断。

8.2 异常值处理

本阶段主要处理 adr 房价异常和入住天数异常。adr 表示平均每日房价，根据业务逻辑，房价不应为负，因此先删除 adr 小于 0 的记录。对于极端高值，使用 IQR 法则识别并筛除。

入住天数通过 stays_in_weekend_nights 与 stays_in_week_nights 求和得到 total_stays，随后对 total_stays 使用 IQR 法则识别并筛除异常入住天数。

异常对象	处理规则
adr	删除负值，并使用 IQR 法则筛除极端高值。
total_stays	由周末入住晚数和工作日入住晚数相加得到，再使用 IQR 法则筛除异常值。

8.3 数据去重

项目说明要求基于预订唯一标识去重，但当前数据集中没有明确的预订 ID 或订单唯一标识字段。因此本阶段无法基于唯一标识去重，仅进行完全重复行检查。检查结果显示完全重复行数量为 0，因此本阶段没有实际删除重复记录。

8.4 时间格式统一

本阶段将 reservation_status_date 转换为 datetime 类型，并使用 arrival_date_year、arrival_date_month、arrival_date_day_of_month 构造 arrival_date。日期转换失败数量为 0，说明当前日期字段可以正常解析。

九、清洗结果

清洗后数据保存为 data/processed/hotel_bookings_cleaned.csv，并进一步转换为 Parquet 格式：data/processed/hotel_bookings_cleaned.parquet。

指标	结果
清洗后行数	110628
清洗后列数	35

新增字段 1	total_stays: 总入住晚数。
新增字段 2	arrival_date: 标准化入住日期。

十、自动化数据质量校验脚本

本阶段开发了自动化数据质量校验脚本 `src/data/data_quality_check.py`。该脚本支持默认检查当前原始数据，也支持通过参数传入同结构的新数据文件。

检查类型	检查内容
完整性检查	字段是否齐全、是否有额外字段、缺失值统计、是否空数据。
一致性检查	目标变量合法性、负数检查、入住晚数检查、日期解析检查。
唯一性检查	完全重复行、可能的 ID 字段、ID 字段唯一性。

该脚本可以用于后续同结构数据的快速质量复查，例如下一年度酒店预订数据。

十一、数据预处理与中间表构建

本阶段开发了中间表构建脚本 `src/data/build_intermediate_tables.py`。脚本基于清洗后的 CSV 数据完成数据类型压缩、清洗后数据转换为 Parquet、建模基础表构建和四张基础中间表构建。

表名	行数	列数
hotel_bookings_cleaned.parquet	110628	35
modeling_base.parquet	110628	33
customer_profile_table.parquet	121	11

hotel_summary_table.parquet	30	8
time_dimension_table.parquet	366	7
booking_behavior_by_arrival_date.parquet	366	7

需要说明的是，当前数据没有明确 `user_id`，因此用户维度表不是严格意义上的单用户画像表，而是基于客户类型和渠道字段聚合的客户群体画像表。

当前未引入外部节假日数据，因此时间维度表只构造年、月、周、日、星期和是否周末字段，暂不包含节假日字段。

十二、代码规范处理

- 将数据处理逻辑拆分为多个脚本，避免全部代码堆在 Notebook 中。
- 新增 `src/config.py` 统一管理路径、目标变量和字段列表。
- 在关键逻辑前添加注释。
- 使用类型提示提升代码可读性。
- 对脚本进行基础语法检查。
- 对代码进行基础 PEP8 检查，确认无超过 88 字符行、无尾随空格、无 `tab`。

十三、阶段产出

类别	产出文件
文档	<code>docs/git_workflow.md</code> ; <code>docs/intermediate_tables.md</code>
Notebook	<code>notebooks/data_preprocessing.ipynb</code>
配置与脚本	<code>src/config.py</code> ; <code>src/data/data_preprocessing.py</code> ; <code>src/data/data_quality_check.py</code> ; <code>src/data/build_intermediate_tables.py</code>

清洗后数据	data/processed/hotel_bookings_cleaned.csv; data/processed/hotel_bookings_cleaned.parquet; data/processed/modeling_base.parquet
中间表	customer_profile_table.parquet; hotel_summary_table.parquet; time_dimension_table.parquet; booking_behavior_by_arrival_date.parquet

十四、后续计划

- 与老师确认项目说明中列出的文献是否为指定材料。
- 补充领域文献调研和读书笔记。
- 进入下一阶段探索性数据分析和特征工程。
- 关注潜在数据泄漏字段，例如 reservation_status 和 reservation_status_date。

十五、阶段总结

本周完成了第一阶段中除文献调研外的大部分工程与数据处理任务。当前项目已经具备规范的目录结构、Git 分支管理、原始数据质量检查、数据清洗流程、自动化质量校验脚本、清洗后数据集和基础中间表，为后续探索性分析和建模工作奠定了数据基础。领域文献调研仍需在后续完成。